



Visión por Computadora

PROYECTO TUTTI FRUTTI

IA acelerada con GPU



Juan Cruz Rey, Lucas Carmusciano, Santiago Minnaar Vizzotto y Paula Goldenhorn

Pipeline

1 **Recolección de imágenes propias**
Dataset de imágenes recolectadas de **internet** y tomadas **manualmente**.

2 **Anotaciones**
Imágenes anotadas con **Roboflow**.

3 **Fine-Tuning**
Entrenamiento con **YOLOV26** para **segmentación** en **GPU** (Colab T4).

4 **Inferencia**
Predicciones del mejor modelo sobre **video propio** con **OpenCV**.




5 **Benchmark CPU vs GPU**
Comparación de tiempos (**latencia**, **FPS**) y memoria (**VRAM**).

6 **Conclusión**
Análisis final.

1. Recolección




2. Anotaciones





3. Fine-Tuning

Resultados de entrenamiento




3. Fine-Tuning




3. Fine-Tuning

Predicciones sobre imágenes de test

1 detecciones




4 detecciones



0 detecciones



9 detecciones



2 detecciones



1 detecciones



*Resultados de predicciones sobre dataset de **test***

3. Fine-Tuning

*Resultados de predicciones sobre dataset de
validación*


Métricas de validación

mAP@50 : 0.6013

mAP@50-95 : 0.5271

Precisión : 0.6417


Recall : 0.5874




4. Inferencia

Detección y Segmentación sobre video propio


Segmentación sobre video — frames seleccionados



Frame #319
3 detecciones



Frame #638
2 detecciones



Frame #958
3 detecciones



Segmentación sobre video — frames seleccionados

Frame #0
25 detecciones




Frame #111
33 detecciones



Frame #222
49 detecciones



Frame #334
33 detecciones



5. Benchmark

Tiempos y Memoria

*Estimación de cantidad de datos
procesados por inferencia*

	Latencia promedio	Desviación estándar	FPS estimados	Throughput	
CPU	159.86 ms	26.93 ms	6.26	6.26	15 inferencias
GPU	48.06 ms	27.74 ms	20.81	20.81	30 inferencias

VRAM máxima usada (GPU) : 1231.74 MB

Speed Up: 3.33 x

6. Conclusión

La GPU demuestra una mejora sustancial en el rendimiento, siendo **3.33 veces más rápida** en términos de **Speedup** que la CPU para la inferencia del modelo.

Esto principalmente se debe al aprovechamiento de la paralelización de operaciones que puede realizar la GPU, subrayando la importancia de la aceleración por hardware para **tareas de visión por computadora** donde los datos a tratar son **matrices numéricas**.

Exportar mejor modelo

Optimización

```
# ONNX — compatible con cualquier plataforma
export_onnx = model_best.export(
    format="onnx",
    opset=17,
    dynamic=True,
    imgsz=IMGSZ,
)
print(f"ONNX exportado: {export_onnx}")
```

¡Veamos una DEMO en vivo!

*Utilizaremos el mejor modelo para realizar una
inferencia sobre un video*